

岭回归与Lasso回归的出现是为了解决线性回归出现的过拟合以及在通过正规方程方法求解  $\theta$  的过程中出现的  $x$  转置乘以  $x$  不可逆这两类问题的，这两种回归均通过在损失函数中引入正则化项来达到目的，具体三者的损失函数对比见下图：

线性回归的损失函数：
$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

岭回归的损失函数：
$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n \theta_j^2$$

Lasso回归的损失函数：
$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \lambda \sum_{j=1}^n |\theta_j|$$

其中  $\lambda$  称为正则化参数，如果  $\lambda$  选取过大，会把所有参数  $\theta$  均最小化，造成欠拟合，如果  $\lambda$  选取过小，会导致对过拟合问题解决不当，因此  $\lambda$  的选取是一个技术活。

岭回归与Lasso回归最大的区别在于岭回归引入的是L2范数惩罚项，Lasso回归引入的是L1范数惩罚项，Lasso回归能够使得损失函数中的许多  $\theta$  均变成0，这点要优于岭回归，因为岭回归是要所有的  $\theta$  均存在的，这样计算量Lasso回归将远远小于岭回归。

从概念上讲，我们可以说，Lasso回归（L1）同时做变量选择和参数收缩，而ridge回归只做参数收缩，并最终在模型中包含所有的系数。在有相关变量时，ridge回归可能是首选。此外，ridge回归在用最小二乘估计有更高的偏差的情况下效果最好。因此，选择合适的模型取决于我们的模型的目标。