

局部加权线性回归

局部加权线性回归算法，是一种非参数学习方法（non-parametric）：

$$J(\theta) = \sum_{i=1}^m w^{(i)} [y^{(i)} - \theta^T x^{(i)}]^2 \quad \text{其中: } w^{(i)} = e^{-\frac{(x^{(i)} - x)^2}{2k^2}}$$

对于上述公式的理解是这样的： x 为某个预测点， $x^{(i)}$ 为样本点，样本点距离预测点越近，贡献的误差越大（权值越大），越远则贡献的误差越小（权值越小）。关于预测点的选取，在我的代码中取的是样本点。其中 k 是带宽参数，控制 w （钟形函数）的宽窄程度，类似于高斯函数的标准差。

算法思路：假设预测点取样本点中的第 i 个样本点（共 m 个样本点），遍历1到 m 个样本点（含第 i 个），算出每一个样本点与预测点的距离，也就可以计算出每个样本贡献误差的权值，可以看出 w 是一个有 m 个元素的向量（写成对角阵形式），代入上式 $J(\theta)$ 中。

$$w = \begin{bmatrix} w_1 & & & \\ & \ddots & & \\ & & w_i & \\ & & & \ddots \\ & & & & w_m \end{bmatrix} \quad J(\theta) = \sum_{i=1}^m w^{(i)} [y^{(i)} - \theta^T x^{(i)}]^2$$
$$= y^T w y - \theta^T x^T w y - y^T w^T x \theta + \theta^T x^T w x \theta$$

利用最小二乘法，可以计算出一个 θ 向量（一个预测点对应一个向量）

$$\nabla_{\theta} J(\theta) = 0$$
$$-x^T w y - x^T w y + 2x^T w x \theta = 0$$
$$\theta = (x^T w x)^{-1} x^T w y$$

如此下去， i 从1取到 m ，就可以计算出 m 个 θ 向量。

岭回归（加入L2范数正则化）

岭回归(Ridge Regression)是在平方误差的基础上增加正则项

$$\sum_{i=1}^n \left(y_i - \sum_{j=0}^p w_j x_{ij} \right)^2 + \lambda \sum_{j=0}^p w_j^2$$

通过确定 λ 的值可以使得在方差和偏差之间达到平衡：随着 λ 的增大，模型方差减小而偏差增大。

对 w 求导，结果为

$$2X^T(Y - XW) - 2\lambda W$$

令其为0，可求得 w 的值：

$$\hat{w} = (X^T X + \lambda I)^{-1} X^T Y$$

最先用来处理特征数多于样本数的情况，现在也用于在估计中加入偏差，从而得到更好的估计。通过引入 λ 限制了所有 w 之和，通过引入该惩罚项，能减少不重要的参数，在统计学中叫缩减（shrinkage）。

Lasso（Least Absolute Shrinkage and Selection Operator）（L1范数正则化）

$$\min_w \sum_{i=1}^m (y_i - w^T x_i)^2 + \lambda \|w\|_1$$

在 λ 足够小的时候，一些系数会因此被迫缩减到0，容易获得“稀疏解”，所以lasso在压缩感知中应用广泛。但是需要二次规划方法来求解

Lasso 回归主要的解法有两种：坐标轴下降法 (coordinate descent) 和最小角回归法 (Least Angle Regression)。