


Fisherface是由Ronald Fisher发明的，想必这就是Fisherface名字由来。Fisherface所基于的LDA（Linear Discriminant Analysis，线性判别分析）理论和[特征脸](#)里用到的[PCA](#)有相似之处，都是对原有数据进行整体降维映射到低维空间的方法，LDA和PCA都是从数据整体入手而不同于LBP提取局部纹理特征。如果阅读本文有难度，可以考虑自学斯坦福公开课机器学习或者补充线代等数学知识。

同时作者要感谢cnblogs上的大牛JerryLead，本篇博文基本摘自他的线性判别分析（Linear Discriminant Analysis）[1]。

## 1、数据集是二类情况

通常情况下，待匹配人脸要和人脸库内的多张人脸匹配，所以这是一个多分类的情况。出于简单考虑，可以先介绍二类的情况然后拓展到多类。假设有二维平面上的两个点集 $x$ （ $x$ 是包含横纵坐标的二维向量），它们的分布如下图（1）（分别以蓝点和红点表示数据）：



原有数据是散布在平面上的二维数据，如果想用一维的量（比如到圆点的距离）来合理的表示而且区分开这些数据，该怎么办呢？一种有效的方法是找到一个合适的向量 $w$ （和数据相同维数），将数据投影到 $w$ 上（会得到一个标量，直观的理解就是投影点到坐标原点的距离），根据投影点来表示和区分原有数据。以数学公式给出投影点到到原点的距离： $y=wTx$ 。图（1）给出了两种 $w$ 方案， $w$ 以从原点出发的直线来表示，直线上的点是原数据的投影点。直观判断右侧的 $w$ 更好些，其上的投影点能够合理的区分原有的两个数据集。但是计算机不知道这些，所以必须要有确定的方法来计算这个 $w$ 。

首先计算每类数据的均值（中心点）：

这里的 $i$ 是数据的分类个数， $N_i$ 代表某个分类下的数据点数，比如 $u_1$ 代表红点的中心， $u_2$ 代表蓝点的中心。

数据点投影到w上的中心为：

$$\tilde{\mu}_i = \frac{1}{N_i} \sum_{y \in \omega_i} y = \frac{1}{N_i} \sum_{x \in \omega_i} w^T x = w^T \mu_i$$

如何判断向量w最佳呢，可以从两方面考虑：1、不同的分类得到的投影点要尽量分开；2、同一个分类投影后得到的点要尽量聚合。从这两方面考虑，可以定义如下公式：

$$J(w) = |\tilde{\mu}_1 - \tilde{\mu}_2| = |w^T (\mu_1 - \mu_2)|$$

J(w)代表不同分类投影中心的距离，它的值越大越好。

$$\tilde{s}_i^2 = \sum_{y \in \omega_i} (y - \tilde{\mu}_i)^2$$

上式称之为散列值（scatter matrixs），代表同一个分类投影后的散列值，也就是投影点的聚合度，它的值越小代表投影点越聚合。

结合两个公式，第一个公式做分子另一个做分母：

上式是w的函数，值越大w降维性能越好，所以下面的问题就是求解使上式取最大值的w。

把散列函数展开：

$$\tilde{s}_i^2 = \sum_{y \in \omega_i} (y - \tilde{\mu}_i)^2 = \sum_{x \in \omega_i} (w^T x - w^T \mu_i)^2 = \sum_{x \in \omega_i} w^T (x - \mu_i)(x - \mu_i)^T w$$

可以发现除w和w<sup>T</sup>外，剩余部分可以定义为：

$$S_i = \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T$$

其实这就是原数据的散列矩阵了，对不对。对于固定的数据集来说，它的散列矩阵也是确定的。

另外定义：

$S_w$ 称为Within-class scatter matrix。

回到并用上面的两个定义做替换，得到：

$$\tilde{s}_1^2 + \tilde{s}_2^2 = w^T S_w w$$

展开 $J(w)$ 的分子并定义 $S_B$ ， $S_B$ 称为Between-class scatter。

$$(\tilde{\mu}_1 - \tilde{\mu}_2)^2 = (w^T \mu_1 - w^T \mu_2)^2 = w^T \underbrace{(\mu_1 - \mu_2)(\mu_1 - \mu_2)^T}_{S_B} w = w^T S_B w$$

这样就得到了 $J(w)$ 的最终表示：

上式求极大值可以利用[拉格朗日乘数法](#)，不过需要限定一下分母的值，否则分子分母都变，怎么确定最好的 $w$ 呢。可以令，利用拉格朗日乘数法得到：

$$\begin{aligned} c(w) &= w^T S_B w - \lambda (w^T S_w w - 1) \\ \Rightarrow \frac{dc}{dw} &= 2S_B w - 2\lambda S_w w = 0 \\ \Rightarrow S_B w &= \lambda S_w w \end{aligned}$$

其中 $w$ 是矩阵，所以求导时可以把当做一个标量。（这点我也不懂）

上式两边同乘以 $w^T$ 可以得到：

可以发现 $w$ 其实就是矩阵的特征向量了，对不对。

通过上式求解 $w$ 还是有些困难的，而且 $w$ 会有多个解，考虑下式：

$$S_B = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

将其带入下式：

$$S_B w = (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T w = (\mu_1 - \mu_2) * \lambda_w$$

其中  $\lambda_w$  是以  $w$  为变量的数值，因为  $(\mu_1 - \mu_2)^T$  和  $w$  是相同维数的，前者是行向量后者列向量。继续带入以前的公式：

$$S_w^{-1} S_B w = S_w^{-1} (\mu_1 - \mu_2) * \lambda_w = \lambda w$$

由于  $w$  扩大缩小任何倍不影响结果，所以可以约去两遍的未知常数  $\lambda$  和  $\lambda_w$ （存疑）：


$$w = S_w^{-1} (\mu_1 - \mu_2)$$

到这里， $w$  就能够比较简单的求解了。

## 2、数据集是多类的情况

这部分是本博文的核心。假设有  $C$  个人的人脸图像，每个人可以有多张图像，所以按人来分，可以将图像分为  $C$  类，这节就是要解决如何判别这  $C$  个类的问题。判别之前需要先处理下图像，将每张图像按照逐行逐列的形式获取像素组成一个向量，和第一节类似设该向量为  $x$ ，设向量维数为  $n$ ，设  $x$  为列向量（ $n$  行 1 列）。

和第一节简单的二维数据分类不同，这里的  $n$  有可能成千上万，比如  $100 \times 100$  的图像得到的向量为 10000 维，所以第一节里将  $x$  投影到一个向量的方法可能不适用了，比如下图：



图（2）

平面内找不到一个合适的向量，能够将所有的数据投影到这个向量而且不同类间合理的分开。所以我们需要增加投影向量 $w$ 的个数（当然每个向量维数和数据是相同的，不然怎么投影呢），设 $w$ 为：

$w_1$ 、 $w_2$ 等是 $n$ 维的列向量，所以 $w$ 是个 $n$ 行 $k$ 列的矩阵，这里的 $k$ 其实可以按照需要随意选取，只要能合理表征原数据就好。 $x$ 在 $w$ 上的投影可以表示为：

所以这里的 $y$ 是 $k$ 维的列向量。

像上一节一样，我们将从投影后的类间散列度和类内散列度来考虑最优的 $w$ ，考虑图（2）中二维数据分为三个类别的情况。与第一节类似， $\mu_i$ 依然代表类别 $i$ 的中心，而 $S_w$ 定义如下：

其中：

$$S_{wi} = \sum_{x \in \omega_i} (x - \mu_i)(x - \mu_i)^T$$

代表类别i的类内散列度，它是一个nxn的矩阵。

所有x的中心  $\mu$  定义为：

$$\mu = \frac{1}{N} \sum_{\forall x} x = \frac{1}{N} \sum_{x \in \omega_i} N_i \mu_i$$

类间散列度定义和上一节有较大不同：

$$S_B = \sum_{i=1}^C N_i (\mu_i - \mu)(\mu_i - \mu)^T$$

代表的是每个类别到  $\mu$  距离的加和，注意 $N_i$ 代表类别i内x的个数，也就是某个人的人脸图像个数。

上面的讨论都是投影之间的各种数据，而 $J(w)$ 的计算实际是依靠投影之后数据分布的，所以有：

$$\widetilde{S}_w = \sum_{i=1}^C \sum_{y \in \omega_i} (y - \widetilde{\mu}_i)(y - \widetilde{\mu}_i)^T$$

$$\widetilde{S}_B = \sum_{i=1}^C N_i (\widetilde{\mu}_i - \widetilde{\mu})(\widetilde{\mu}_i - \widetilde{\mu})^T$$

分别代表投影后的类别*i*的中心，所有数据的中心，类内散列矩阵，类间散列矩阵。与上节类似J(w)可以定义为：

回想我们上节的公式J(w)，分子是两类中心距，分母是每个类自己的散列度。现在投影方向是多维了（好几条直线），分子需要做一些改变，我们不是求两两样本中心距之和（这个对描述类别间的分散程度没有用），而是求每类中心相对于全样本中心的散列度之和。得到：

$$J(w) = \frac{|\widetilde{S}_B|}{|\widetilde{S}_w|} = \frac{|W^T S_B W|}{|W^T S_w W|}$$

最后化为：


还是求解矩阵的特征向量，然后根据需求取前k个特征值最大的特征向量。

另外还需注意：

由于SB中的（ $\mu_i - \mu$ ）秩为1，所以SB的至多为C（矩阵的秩小于等于各个相加矩阵的和）。又因为知道了前C-1个 $\mu_i$ 后，最后一个 $\mu_c$ 可以用前面的 $\mu_i$ 来线性表示，因此SB的秩至多为C-1，所以矩阵的特征向量个数至多为C-1。因为C是数据集的类别，所以假设有N个人的照片，那么至多可以取到N-1个特征向量来表征原数据。（存疑）

如果你读过前面的一篇文章[PCA理论分析](#)，会知道PCA里求得特征向量都是正交的，但是这里的并不是对称的，所以求得的K个特征向量不一定正交，这是LDA和PCA最大的不同。

如前所述，如果在一个人脸集合上求得k个特征向量，还原为人脸图像的话就像下面这样：



得到了 $k$ 个特征向量，如何匹配某人脸和数据库内人脸是否相似呢，方法是将这个人脸在 $k$ 个特征向量上做投影，得到 $k$ 维的列向量或者行向量，然后和已有的投影求得欧式距离，根据阈值来判断是否匹配。具体的方法在[人脸识别经典算法一：特征脸方法 \(Eigenface\)](#)里有，可前往查看。需要说明的是，LDA和PCA两种方法对光照都是比较敏感的，如果你用光照均匀的图像作为依据去判别非均匀的，那基本就惨了。

参考文献：

[1]Jerry Lead[线性判别分析 \(Linear Discriminant Analysis\) \(一\)](#)

[2][http://docs.opencv.org/modules/contrib/doc/facerec/facerec\\_tutorial.html](http://docs.opencv.org/modules/contrib/doc/facerec/facerec_tutorial.html)